

修士論文要旨

Summary of the Master's Thesis

学生番号 Student ID number	M243422	プログラム Program	情報科学プログラム
氏名 Name	廣池 友哉	主指導教員 Supervisor	古居 彬
論文題目 Thesis Title	Adaptive PolyDice Loss with Uncertainty-Based Difficulty Estimation for Medical Image Segmentation		

1 はじめに

医用画像セグメンテーションは、診断支援や治療計画において不可欠な技術であり、正常組織または異常組織の領域を抽出することが求められる。特に大腸ポリープ [1] の検出など、臨床応用が進んでいる。

しかしながら、医用画像セグメンテーションには固有の課題が存在する。特に重要な問題として、クラス不均衡が挙げられる。医用画像では背景領域が大部分を占め、対象となる病変は相対的に小さい領域しか占めないことが多い。この状況下では、従来の分類タスクで広く使われている Cross-Entropy Loss [2] は背景領域の学習に偏り、臨床的に重要な小病変や曖昧な境界部分の正確なセグメンテーションが困難となる。

この課題に対処するため、クラス不均衡に対して頑健な Dice Loss [3] やその多くの拡張手法が提案され、CT 画像や MRI 画像において高い性能が報告されている。しかし、これらの損失関数は全画像に対して固定的な形状を持つという制約がある。医用画像は、撮影条件や個体差など大きな多様性を有しており、画像ごとにセグメンテーションの難易度が大きく異なる。固定的な損失関数を用いると、容易な画像と困難な画像に対して同一の学習信号を与えるため、困難な画像に対する学習が不十分となる可能性がある。したがって、画像ごとの難易度に応じて損失関数を適応的に調整するアプローチが有望である。このような適応的学習の実現には、2つの要素が求められる。1つは、難易度の高い画像に対して学習信号を強化できるよう、損失関数の形状を柔軟に制御する手法である。もう1つは、各画像がモデルにとってどの程度困難であるかを学習中に評価するための難易度指標である。

本研究では、これら2つの要素を統合した適応的学習

フレームワークを提案する。損失関数の形状制御には、Dice Loss を多項式展開して得られる PolyDice Loss [4] を用いる。PolyDice Loss は画像毎に最適なパラメータを用いて損失関数の形状を連続的に制御できるため、適応的学習に適している。難易度の定量化には、Monte Carlo Dropout [5] (以下、MC Dropout) による不確実性推定を用いる。MC Dropout は、推論時に Dropout を有効にすることで、モデルの認識的不確実性を効率的に推定できる。この不確実性は、モデルがその画像のセグメンテーションにおいてどの程度の確信を持っていないかを反映しており、セグメンテーション難易度の指標として利用可能である。提案手法では、推定された不確実性指標に基づき PolyDice Loss の形状パラメータを動的に制御し、困難な画像には急峻な勾配を、容易な画像には緩やかな勾配を与えることで、効率的かつ頑健な学習の実現を目指す。

2 予備知識

2.1 PolyDice Loss

医用画像セグメンテーションで広く使用される Dice Loss は、クラス不均衡に頑健であるが、全画像に対して固定的な形状を持つという制約がある。本研究では、Dice Loss を多項式展開により拡張した PolyDice Loss [4]、特にその実用的な形式である PolyDice-1 Loss を採用する。PolyDice-1 Loss は、単一のパラメータ ϵ で損失関数の形状を制御でき、画像の難易度に応じて勾配の急峻さを調整することが可能となる。

2.1.1 Dice Loss の定義

画像サイズを $H \times W$ とし、ピクセル位置を (i, j) で表す ($i \in \{1, \dots, H\}, j \in \{1, \dots, W\}$)。セグメンテーションタスクにおいて、モデルの予測確率マップを $\hat{Y} =$

$\{\hat{g}_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$, その画像に対する正解マスクを $\mathbf{Y} = \{y_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ とすると, Dice Loss は次式で定義される。

$$\mathcal{L}_{\text{Dice}}(\hat{\mathbf{Y}}, \mathbf{Y}) = 1 - \frac{2 \sum_{j=1}^W \sum_{i=1}^H \hat{g}_{i,j} y_{i,j}}{\sum_{j=1}^W \sum_{i=1}^H (\hat{g}_{i,j}^2 + y_{i,j}^2)} \quad (1)$$

2.1.2 幾何学的解釈と多項式展開

予測確率マップ $\hat{\mathbf{Y}}$ と正解マスク $\mathbf{Y}$ をそれぞれ長さ $H \times W$ のベクトル $\hat{\mathbf{y}}, \mathbf{y}$ として平坦化すると, Dice Loss は以下のように分解できる。

$$\mathcal{L}_{\text{Dice}} = 1 = s \cos \theta \quad (2)$$

ここで, $s = \frac{2\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\|^2 + \|\mathbf{y}\|^2}$ はスケール成分, $\theta = \arccos \frac{\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\| \|\mathbf{y}\|}$ は 2 つのベクトル間の角度を表す。この分解により, Dice Loss はスケール成分 s と $\cos \theta$ の積として理解できる。

学習の進行に伴い $\hat{\mathbf{Y}}$ が $\mathbf{Y}$ に近づく ($\theta \rightarrow 0$) ことに着目し, 方向成分 $\cos \theta$ に対して $\theta = 0$ まわりで Taylor 展開を適用することで多項式形式への拡張が可能となる。

$$\begin{aligned} \mathcal{L}_{\text{PolyDice}} = 1 &= s \left(1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \dots \right) \\ &= (1 - s) + s \sum_{k=1}^{\infty} \alpha_k \theta^{2k} \end{aligned} \quad (3)$$

ここで, $\alpha_k = \frac{(-1)^{k-1}}{(2k)!}$ は各 Taylor 項の符号係数である。

2.1.3 PolyDice-1 Loss

本研究では PolyDice Loss [4] において第 1 項のみを調整する PolyDice-1 Loss を採用する。

$$\mathcal{L}_{\text{PolyDice-1}} = (1 - s) + s \left(\frac{1}{2} + \epsilon \right) \theta^2 \quad (4)$$

ここで, $\epsilon \in \mathbb{R}$ は損失関数の形状を制御するハイパーパラメータで, $\epsilon > 0$ では予測誤差に対するペナルティが強化され, $\epsilon < 0$ では緩和される。後述する提案手法では, この ϵ を動的に調整することで, 個々の画像の難易度に応じた勾配制御を実現し, 学習戦略をサンプル単位で最適化することを可能にしている。

2.2 MC Dropout の原理と応用

Dropout は, ニューラルネットワークの過学習を防ぐ正則化手法として提案された [6]。訓練時に各層のニューロンを確率 p でランダムに不活性化することで, モデルの汎化性能を向上させる。通常, 推論時には Dropout は無効化され, 全ニューロンが活性化された状態で決定論的な予測が行われる。

MC Dropout [5] は, 学習時のみだけでなく, 推論時にも Dropout を有効にすることで, モデルの認識的不




図 1 Overview of the proposed adaptive learning framework

確実性を推定する手法である。Dropout を有効にした状態で推論を行うと, 各推論において異なるニューロンが不活性化されるため, 実質的に異なる部分ネットワークによる予測が得られる。同一入力に対してこの確率的な推論を複数回実行して得られる予測結果の分布は, Bayesian Neural Network における予測事後分布近似とみなせ, 変分推論の一種として解釈できる。提案法では, MC Dropout による推定される認識的不確実性を, 画像のセグメンテーション難易度を反映する指標として活用し, 損失関数の適応的制御に利用する。

3 提案法

3.1 概要

訓練データセットを $D = \{(\mathbf{X}_n, \mathbf{Y}_n)\}_{n=1}^N$ とする。ここで, N は訓練画像の総数, $\mathbf{X}_n \in \mathbb{R}^{H \times W \times C}$ は n 番目の入力画像 (C はチャンネル数), $\mathbf{Y}_n = \{y_{n,i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ は対応する正解マスクである。MC Dropout による不確実性推定では, 各画像に対して T 回の確率的推論を行う。 t 回目の推論 ($t \in \{1, \dots, T\}$) における予測確率マップを $\hat{\mathbf{Y}}_n^{(t)} = \{\hat{y}_{n,i,j}^{(t)}\}_{i,j}$ と表記する。

図 1 に提案手法の概要を示す。提案法では, 学習中各画像に対して r エポックごとに MC Dropout を用いて画像毎に複数枚推論を行い, 予測のばらつきから不確実性を定量化する。この不確実性情報は, モデルがその画像のセグメンテーションにおいてどの程度の確信を持っていないかを反映する。その後, この不確実性情報を画像単位に集約し, PolyDice Loss の形状を動的に制御することで, 難しい画像には急峻な勾配を, 簡単な画像には緩やかな勾配を与える。更新された ϵ を次の r エポック間の学習に適用することで, 学習の進捗度に応じて最適化の重み付けを動的に変化させる適応的学習を実現する。

3.2 不確実性に基づく画像難易度の定量化

3.2.1 学習中の MC Dropout 推論

提案法では、学習プロセスを初期学習期間と適応的学習期間の2段階に分割する。エポック 1 から $E_0 - 1$ までの期間は初期学習期間とし、損失形状パラメータ ϵ を θ に固定して学習を行う。適応的学習期間 ($e \geq E_0$) においては、周期 τ ごとに不確実性の再評価と ϵ の更新を行う。すなわち、更新は $e \in \{E_0, E_0 + \tau, E_0 + 2\tau, \dots\}$ を満たすエポックの学習開始前に実行される。更新の際は、その時点のモデルパラメータ $\mathbf{W}$ を固定し、訓練データの各画像 $\mathbf{X}_n \in \{\mathbf{X}_n\}_{n=1}^N$ に対して Dropout 率 $p \in (0, 1)$ で T 回の確率的推論を行う。得られる予測集合を $\{\hat{\mathbf{Y}}^{(n)}\}_{n=1}^T$ とする：

$$\hat{\mathbf{Y}}^{(n)} = f_{\mathbf{W}}(\mathbf{X}_n; \mathbf{z}^{(n)}), \quad \mathbf{z}^{(n)} \sim \text{Bernoulli}(1 - p) \quad (5)$$

ここで、 $\mathbf{z}^{(n)}$ は n 回目の推論における Dropout マスクであり、 $\hat{\mathbf{Y}}^{(n)}$ はその予測確率マップである。この確率的推論により得られる予測のばらつきから、モデルの認識的不確実性を定量化する。

3.2.2 ピクセル単位の不確実性指標の計算

MC Dropout によって得られた T 枚の予測画像に対し、ピクセル単位の不確実性指標として認識的不確実性を直接捉えることができる相互情報量 $I_{n,i,j}$ を計算する。

$$I_{n,i,j} = H \left(\underbrace{\frac{1}{T} \sum_{t=1}^T \hat{y}_{n,i,j}^{(t)}}_{\text{Entropy of Mean}} \right) - \underbrace{\frac{1}{T} \sum_{t=1}^T H \left(\hat{y}_{n,i,j}^{(t)} \right)}_{\text{Mean of Entropy}} \quad (6)$$

ここで、 $H(p)$ は 2 値分類におけるバイナリエントロピー関数であり、次式で定義される。

$$H(p) = -p \log p - (1 - p) \log(1 - p) \quad (7)$$

認識的不確実性は、予測エントロピーから期待エントロピーを減ずることで定量化できる。ここで、予測エントロピーは T 回の推論結果を平均化した後の予測分布に対する不確実性であり、データとモデルの両方に由来する一方、期待エントロピーは個々の推論における不確実性の平均でありデータ固有のノイズや曖昧さに由来する。相互情報量の値が高い領域はモデルが十分に学習できていないことを示唆する。

3.2.3 画像単位への集約

ピクセル単位の相互情報量から外れ値を除去した後の平均値を、画像全体の難易度指標として集約して定量化する。集約する際、不均衡な医用画像の病変部の不確実性を定量化するため、本手法では計算対象を正解マスク

における陽性領域 $\mathcal{P}_n = \{(i, j) \in \Omega_n \mid y_{i,j} = 1\}$ に限定する。ここで、 Ω_n は画像領域全体を表す。具体的な算出には、突発的なノイズの影響を排除するために統計的な外れ値除去を適用する。 $\mathcal{P}_n$ 内の平均 $\mu_{\mathcal{P}_n}$ と標準偏差 $\sigma_{\mathcal{P}_n}$ を用いて有効画素集合 $\mathcal{P}'_n$ を定義する。

$$\mathcal{P}'_n = \{(i, j) \in \mathcal{P}_n \mid \mu_{\mathcal{P}_n} - 2\sigma_{\mathcal{P}_n} \leq I_{n,i,j} \leq \mu_{\mathcal{P}_n} + 2\sigma_{\mathcal{P}_n}\} \quad (8)$$

この有効集合 $\mathcal{P}'_n$ を用いて、画像全体の難易度スコア D_n は次式で算出される。

$$D_n = \frac{1}{|\mathcal{P}'_n|} \sum_{(i,j) \in \mathcal{P}'_n} I_{n,i,j} \quad (9)$$

なお、 $\mathcal{P}_n = \emptyset$ の場合は $D_n = 0$ とする。

次に、各サンプルの相対的な難易度を決定するため、データセット全体の難易度スコア分布に基づいて正規化を行う。データセット全体のスコア集合 $\{D_n\}_{n=1}^N$ に対し、 q パーセンタイル値を D_q 、標準偏差を σ_D とすると、正規化されたスコア D_n^{norm} は次のように計算される。

$$D_n^{\text{norm}} = \frac{D_n - D_q}{\sigma_D + \delta} \quad (10)$$

ここで、 δ は数値的安定性のための微小定数である。 D_q による減算は、後述する制御関数への入力を合わせるための中心化をする役割を持つ。分布の平均値ではなく q パーセンタイル値を用いることで、容易なサンプルが多数を占める分布においても、外れ値の影響を受けずに難易度の基準点を柔軟に設定できる。 σ_D による除算は尺度の統一であり、制御関数の感度がデータセットごとの不確実性のスケールに依存しないように調整する役割を持つ。

3.3 適応的損失形状制御

3.3.1 制御関数の設計

得られた難易度指標 D_n^{norm} に基づき、PolyDice-1 Loss の形状パラメータ ϵ を動的に更新する。更新式には以下のシグモイドベースの制御関数を用いる。

$$\epsilon = \epsilon_{\min} + (\epsilon_{\max} - \epsilon_{\min}) \sigma(k \cdot D_n^{\text{norm}}) \quad (11)$$

ここで、 $\sigma(x) = (1 + e^{-x})^{-1}$ 標準シグモイド関数、 $k > 0$ はパラメータであり、 $\epsilon_{\min}, \epsilon_{\max}$ は ϵ の変動範囲である。シグモイド関数を用いることで、難易度が低い領域から高い領域への遷移を滑らかに行いつつ、出力値を常に所定の範囲内に厳密に制約することが可能となる。パラメータ k は関数の応答感度を制御し、その値が大きいほど難易度判定の境界が急峻になり、小さいほど滑らかな遷移となる。

この制御により、難しい画像 (D_n^{norm} が大きい) に対しては、大きな ϵ を割り当て、損失関数の勾配を急峻に

する。これは、同じ予測誤差に対してより大きな損失値と勾配を与えることを意味し、結果として難しい画像からの学習信号が相対的に強化される。一方、すでに十分に学習できている簡単な画像には小さな ϵ を割り当て、過学習を防ぎつつ学習リソースを難しい画像に集中させる。更新された ϵ は学習に適用され、これによりモデルは困難な画像の学習を重点的に行うことが可能となる。

3.3.2 学習アルゴリズム

学習プロセスは難易度評価と損失パラメータ更新を行う適応的制御と、実際にモデルパラメータを更新する学習段階の2つで構成される。

学習開始時、モデルパラメータ $\mathbf{W}$ を初期化し、全ての画像に対する損失形状パラメータ ϵ を 0 に初期化する。 $E_0 > 0$ の場合、エポック 1 から $E_0 - 1$ までの期間は初期学習期間とし、 $\epsilon = 0$ を固定して標準的な PolyDice-1 Loss で学習を行う。この期間により、モデルは不確実性推定に必要な基礎的な特徴表現を獲得する。 $E_0 = 0$ の場合は、最初のエポックから適応的制御を開始する。

適応的学習期間 ($e \geq E_0$) では、 τ エポックごとに適応的制御が実行される。ここでは、3.2 節で述べた手順に従い、MC Dropout 推論による不確実性指標推定、画像単位への集約、正規化を経て、各画像の ϵ が更新される。適応的制御の段階ではモデルパラメータ $\mathbf{W}$ は固定されており、損失関数の形状パラメータ ϵ の更新のみが行われることに注意されたい。

続く学習段階 (Epoch e) では、更新された ϵ を用いてミニバッチ学習を行う。具体的には、ランダムにサンプリングされたミニバッチを構成する画像のインデックス集合を $\mathcal{B} \subset \{1, \dots, N\}$ とする。このとき、最適化の対象となる目的関数 $\mathcal{L}$ は、バッチ内の各画像 $n \in \mathcal{B}$ に個別に割り当てられた形状パラメータ ϵ_n を用いた PolyDice-1 Loss の平均として次式で定義される。

$$\mathcal{L} = \frac{1}{|\mathcal{B}|} \sum_{n \in \mathcal{B}} \mathcal{L}_{\text{PolyDice-1}}(\hat{\mathbf{Y}}_n, \mathbf{Y}_n; \epsilon_n) \quad (12)$$

ここで、 $\mathcal{L}_{\text{PolyDice-1}}(\cdot; \epsilon_n)$ はパラメータ ϵ_n を適用した単一画像の損失関数を表す。このように、バッチ内の各画像に対して異なる ϵ_n を適用することで、難易度が高いと判定された画像には急峻な勾配を、低い画像には緩やかな勾配を同時に与えることが可能となる。最終的に、この損失関数 $\mathcal{L}$ に基づく勾配降下法により、モデルパラメータ $\mathbf{W}$ が最適化される。このサイクルを繰り返すことで、モデルの学習に応じて困難な画像の学習を重点的に行うことが可能となる。

4 実験

4.1 実験設定

4.1.1 データセット

CVC-ClinicDB データセット [7] データセットおよび Kvasir-SEG データセット [8] を用いて実験を行った。CVC-ClinicDB データセットは 612 枚の大腸内視鏡画像 (384×288 pixel), Kvasir-SEG データセットは 1000 枚の大腸内視鏡画像で、いずれも大腸内視鏡画像とそれに対応するポリープの正解マスクから構成される。データは 5 分割交差検証で分割され、CVC-ClinicDB データセットに関しては同一のビデオシーケンスが異なる fold に跨らないよう、GroupKFold を用いた分割を行った。

4.1.2 実装の詳細

セグメンテーションモデルには U-Net [9] を採用した。学習には Adam optimizer [10] を使用し、バッチサイズ 32, 学習率 10^{-3} に設定した。前処理として全画像を $W = 224$ pixel, $H = 224$ pixel にリサイズし、訓練時には 50% の確率で上下左右反転および明度・コントラストの変更を適用した。最大エポック数 E は 200 に設定した。

MC Dropout による不確実評価は、 $\tau = 10$ エポックごとに実施した。Dropout 層はエンコーダの最終ブロックとデコーダの最終ブロックに配置し、各評価時には、先行研究 [5] を基に $p = 0.5$ で $T = 10$ 回の確率的推論を行った。またデータセット内の難易度指標の正規化時のパーセンタイルは難易度分布の偏りを考慮して $q = 25$ に設定し、予備実験の結果を基に適応的学習の開始エポックは $E_0 = 10$ とし、 $\epsilon_{\min} = 0$, $\epsilon_{\max} = 0.5$, $k = 2$ とした。

4.1.3 比較条件および比較指標

適応的学習の有効性を評価するため、以下の手法と提案法を比較する：

- Dice Loss [3]：医用画像セグメンテーションにおける標準的な損失関数であり、ベースラインとして採用した。
- Focal Loss [11]：易しいサンプルの損失を down-weight することでクラス不均衡に対処する手法で、易しいサンプルの損失を down-weight する割合は $\gamma = 2$ とした。
- PolyDice-1 Loss ($\epsilon = 0$)：PolyDice-1 Loss の標準形式であり、理論上は通常の Dice Loss を近似したものである。提案法および後述する Optimal 設定との比較において、パラメータ ϵ を操作すること

スペース節約のため、統合しましょう。評価指標は絞って良いと思います。

表1 Performance Comparison with Existing Loss Functions on CVC-ClinicDB Dataset

Method	Dice	IoU	Precision	Recall
Dice Loss	0.5408	0.4347	0.6359	0.5819

表1: Performance Comparison on Two Datasets

Method	CVC-ClinicDB		Kvasir-SEG	
	Dice	IoU	Dice	IoU
Dice Loss	0.5408	0.4347	0.7895	0.7021
Focal Loss	0.5007	0.4133	0.7192	0.6082
PolyDice-1 ($\epsilon=0$)	0.5825	0.4808	0.8095	0.7198
PolyDice-1 (Opt.)	0.6145	0.5145	0.8095	0.7198
Adaptive (Ours)	0.6924	0.5262	0.8272	0.7440

Method	Dice	IoU	Precision	Recall
Dice Loss	0.7895	0.7021	0.8281	0.8154
Focal Loss ($\gamma = 2$)	0.7192	0.6082	0.8634	0.6769
PolyDice-1 ($\epsilon = 0$)	0.8095	0.7198	0.8461	0.8268
PolyDice-1 (Opt. $\epsilon = 0.0$)	0.8095	0.7198	0.8461	0.8268
Adaptive PolyDice-1	0.8272	0.7440	0.8707	0.8397

表3 Performance Comparison by Difficulty Group on CVC-ClinicDB Dataset

Difficulty	Dice Loss	Adaptive PolyDice-1	Improvement
Easy	0.8580	0.8602	+0.0022
Normal	0.6366	0.7262	+0.0896
Hard	0.1309	0.4907	+0.3598

自体の純粋な効果を検証するための基準として採用した。

- PolyDice-1 Loss (optimal) : 固定 ϵ による性能の理論的上界を評価するため、テストデータに対する Dice 係数を最大化する ϵ 値を事後的に探索し、これを理想設定として比較に含めた。この設定は実運用では実現不可能であるが、「最適な固定値が事前に既知である」という理想的な条件下での性能を表す。

これらの比較により、(1) 提案法が標準的な損失関数より優れているか、(2) 適応的 ϵ 制御が固定 $\epsilon = 0$ より有効か、(3) 提案法が Optimal 設定に匹敵あるいは上回る性能を達成できるか、を検証する。

またセグメンテーションの性能の評価には、領域の重なりを測る Dice 係数（主指標）および IoU および検出精度を測る Precision および Recall を用いた。最終的な性能評価時の予測マスクには予測マップ Y_n を閾値 0.5 で二値化したものを用い、各指標はテストデータ全体での平均値を報告する。

4.2 結果と議論

4.2.1 比較手法との性能比較：

表1 および表2 に、各データセットにおける比較手法との性能比較を示す。両方のデータセットにおいて、提

表4 Performance Comparison by Difficulty Group on Kvasir-SEG Dataset

Difficulty	Dice Loss	Adaptive PolyDice-1	Improvement
Easy	0.9544	0.9359	-0.0185
Normal	0.8871	0.8869	-0.0002
Hard	0.5288	0.6588	+0.1300




図2 Comparison of Adaptive PolyDice-1 and Dice Loss

案法は全ての比較手法を上回る性能を達成した。この結果から、提案法が難易度に応じた適応的な学習戦略を通じて、セグメンテーション性能を効果的に向上させることが示された。全テストデータに対して Dice 係数を最大化するように設定した固定の ϵ を用いた PolyDice-1 Loss と比較した際、提案法は優れた性能を示した。これは、提案法が画像の難易度に応じて動的に損失形状を調整することで、セグメンテーション性能を効果的に向上させることができることを示唆している。

4.2.2 難易度別の評価

提案手法の設計意図である「困難な症例に対しては急峻な勾配を与え、容易な症例に対しては緩やかな勾配を与える」という適応的学習戦略の有効性を検証するため、症例の難易度に基づいたセグメンテーション性能の比較分析を行った。具体的には、ベースライン手法である Dice Loss におけるテストデータの Dice 係数に基づき、全症例を3つの難易度層に分類した。下位 33% 点未満の症例を「困難 (Hard)」, 33% 点以上 66% 点未満を「中程度 (Medium)」, 66% 点以上を「容易 (Easy)」と定義し、提案手法による精度向上幅を評価した。分析の結果、困難な症例群において最も顕著な精度向上が確認された。これは、予測が不確実で困難な症例に対して大きな ϵ を割り当て、損失関数の勾配を急峻にしたことで、モデルが困難な画像の特徴量を重点的に学習できたことを示唆している。一方で、容易および中程度の症例群においては、精度が困難な症例群と比較して小さな上昇、あるいは僅かな低下に留まった。この結果は、既に十分に学習された症例からの勾配を抑制するという設計意図を反映したものであり、モデルが特定の容易なパターンに対して過学習することを防いだ結果であると解釈できる。

4.2.3 定性的評価

図 2 に、CVC-ClinicDB データセットにおいて、前節で「困難」に分類された画像の比較手法と提案法のセグメンテーション結果の比較の一例を示す。比較画像から確認できるように、ポリープと粘膜壁のコントラストが低く、境界が不明瞭な症例において、ベースラインである Dice Loss や Focal Loss では、ポリープ領域を捉えきれず、著しい過少検出が発生していることがわかる。これに対し、提案法では、高い精度でセグメンテーションを実現している。これは、提案法が MC Dropout によりこのような症例を困難な画像と判定し、損失関数の形状パラメータ ϵ を動的に大きく設定したことで、学習時に当該症例に対する勾配が強化され、モデルが特徴を捉える能力が向上した結果であると考えられる。

5 まとめ

本稿では、医用画像セグメンテーションにおける適応的学習手法を提案した。提案法では、MC Dropout を用いてモデルの認識の不確実性を定量化し、これを画像のセグメンテーション難易度の指標として活用する。得られた難易度指標に基づき、PolyDice-1 Loss の形状パラメータを動的に制御することで、難しい画像には急峻な勾配を、簡単な画像には緩やかな勾配を与える適応的学習を実現した。大腸内視鏡画像データセットを用いた実験により、提案法が既存の損失関数を上回るセグメンテーション性能を達成し、特に困難な症例に対して顕著な性能向上をもたらすことが示された。今後はハイパーパラメータの自動最適化や、CT や MRI などの 3 次元医用画像への拡張に取り組む予定である。

参考文献

- [1] G.-P. Ji *et al.*, “Video polyp segmentation: A deep learning perspective,” *Machine Intelligence Research*, vol. 19, no. 6, pp. 531–549, 2022.
- [2] J. Long *et al.*, “Fully convolutional networks for semantic segmentation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015, pp. 3431–3440.
- [3] F. Milletari *et al.*, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” in *2016 Fourth International Conference on 3D Vision (3DV)*. Ieee, 2016, pp. 565–571.
- [4] H. Aizawa, “Polynomial dice loss for medical image segmentation(submitted).”
- [5] Y. Gal and Z. Ghahramani, “Dropout as a Bayesian approximation: Representing model uncertainty in deep learning,” in *Proceedings of The 33rd International Conference on Machine Learning*, vol. 48, 20–22 Jun 2016, pp. 1050–1059.
- [6] N. Srivastava *et al.*, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.
- [7] J. Bernal *et al.*, “WM-DOVA maps for accurate polyp highlighting in colonoscopy: Validation vs. saliency maps from physicians,” *Computerized Medical Imaging and Graphics*, vol. 43, pp. 99–111, 2015.
- [8] D. Jha *et al.*, “Kvasir-seg: A segmented polyp dataset,” in *Proceedings of the 26th International Conference on Multimedia Modeling (MMM 2020), Part II*, ser. Lecture Notes in Computer Science, vol. 11962. Springer, 2020, pp. 451–462.
- [9] O. Ronneberger *et al.*, “U-net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer, 2015, pp. 234–241.
- [10] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
- [11] T.-Y. Lin *et al.*, “Focal loss for dense object detection,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 2980–2988.