

修士論文要旨

Summary of the Master's Thesis

学 生 番 号 Student ID number	M243422	プ ロ グ ラ ム Program	情報科学プログラム
氏 名 Name	廣池 友哉	主 指 導 教 員 Supervisor	古居 彬
論 文 題 目 Thesis Title	不確実性適応型損失関数による頑健な医用画像セグメンテーション		

1 はじめに

医用画像セグメンテーションは、診断支援や治療計画において不可欠な技術であり、正常組織または異常組織の領域を抽出することが求められる。特に大腸ポリープ [1] や頭頸部がん放射線治療における危険臓器 [2] の検出など、臨床応用が進んでいる。

しかしながら、医用画像セグメンテーションには固有の課題が存在する。特に重要な問題として、クラス不均衡が挙げられる。医用画像では背景領域が大部分を占め、対象となる病変は相対的に小さい領域しか占めないことが多い。この状況下では、従来の分類タスクで広く使われている Cross-Entropy Loss [3] は背景領域の学習に偏り、臨床的に重要な小病変や曖昧な境界部分の正確なセグメンテーションが困難となる。

この課題に対処するため、クラス不均衡に対して頑健な Dice Loss [4] やその多くの拡張手法が提案され、CT 画像 [5,6] や MRI 画像 [7] において高い性能が報告されている。しかし、これらの損失関数は全画像に対して固定的な形状を持つという制約がある。医用画像は、撮影条件や個体差など大きな多様性を有しており、画像ごとにセグメンテーションの難易度が大きく異なる。固定的な損失関数を用いると、容易な画像と困難な画像に対して同一の学習信号を与えるため、困難な画像に対する学習が不十分となる可能性がある。したがって、画像ごとの難易度に応じて損失関数を適応的に調整するアプローチが有望である。このような適応的学習の実現には、2つの要素が求められる。1つは、難易度の高い画像に対して学習信号を強化できるよう、損失関数の形状を柔軟に制御する手法である。もう1つは、各画像がモデルにとってどの程度困難であるかを学習中に評価するための難易度指標である。

本研究では、これら2つの要素を統合した適応的学習

フレームワークを提案する。損失関数の形状制御には、Dice Loss を多項式展開して得られる PolyDice Loss [8] を用いる。PolyDice Loss は画像毎に最適なパラメータを用いて損失関数の形状を連続的に制御できるため、適応的学習に適している。難易度の定量化には、Monte Carlo Dropout [9] (以下、MC Dropout) による不確実性推定を用いる。MC Dropout は、推論時に Dropout を有効にすることで、モデルの認識的不確実性を効率的に推定できる。この不確実性は、モデルがその画像のセグメンテーションにおいてどの程度の確信を持てないかを反映しており、セグメンテーション難易度の指標として利用可能である。提案手法では、推定された不確実性指標に基づき PolyDice Loss の形状パラメータを動的に制御し、困難な画像には急峻な勾配を、容易な画像には緩やかな勾配を与えることで、効率的かつ頑健な学習の実現を目指す。

2 予備知識

2.1 PolyDice Loss

医用画像セグメンテーションで広く使用される Dice Loss は、クラス不均衡に頑健であるが、全画像に対して固定的な形状を持つという制約がある。本研究では、Dice Loss を多項式展開により拡張した PolyDice Loss [8]、特にその実用的な形式である PolyDice-1 Loss を採用する。PolyDice-1 Loss は、単一のパラメータ ϵ で損失関数の形状を制御でき、画像の難易度に応じて勾配の急峻さを調整することが可能となる。

2.1.1 Dice Loss の定義

画像サイズを $H \times W$ とし、ピクセル位置を (i, j) で表す ($i \in \{1, \dots, H\}, j \in \{1, \dots, W\}$)。セグメンテーションタスクにおいて、モデルの予測確率マップを $\hat{\mathbf{Y}} = \{\hat{y}_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ 、その画像に対する正解マスクを $\mathbf{Y} =$

$\{y_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ とすると, Dice Loss は次式で定義される.

$$\mathcal{L}_{\text{Dice}}(\hat{\mathbf{Y}}, \mathbf{Y}) = 1 - \frac{2 \sum_{j=1}^W \sum_{i=1}^H \hat{y}_{i,j} y_{i,j}}{\sum_{j=1}^W \sum_{i=1}^H (\hat{y}_{i,j}^2 + y_{i,j}^2)} \quad (1)$$

2.1.2 幾何学的解釈と多項式展開

予測確率マップ $\hat{\mathbf{Y}}$ と正解マスク $\mathbf{Y}$ をそれぞれ長さ HW のベクトル $\hat{\mathbf{y}}, \mathbf{y}$ として平坦化すると, Dice Loss は以下のように分解できる.

$$\mathcal{L}_{\text{Dice}} = 1 - s \cos \theta \quad (2)$$

ここで, $s = \frac{2\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\|^2 + \|\mathbf{y}\|^2}$ はスケール成分, $\theta = \arccos \frac{\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\| \|\mathbf{y}\|}$ は 2 つのベクトル間の角度を表す. この分解により, Dice Loss はスケール成分 s と $\cos \theta$ の積として理解できる.

方向成分 $\cos \theta$ に対して Taylor 展開を適用することで, PolyDice Loss の多項式表現を導出する. 学習が進むにつれて予測 $\hat{\mathbf{y}}$ は正解 $\mathbf{y}$ に近づくため, 両ベクトルのなす角 θ は 0 に近づく. この性質を利用し, $\cos \theta$ を $\theta = 0$ まわりでテイラー展開すると以下のように近似できる.

$$\cos \theta = 1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \dots \quad (3)$$

これを Dice Loss に代入し, 整理すると PolyDice の一般形が得られる:

$$\mathcal{L}_{\text{PolyDice}} = 1 - s \left(1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \dots \right) \quad (4)$$

$$= (1 - s) + s \sum_{k=1}^{\infty} \alpha_k \theta^{2k} \quad (5)$$

ここで, $\alpha_k = \frac{(-1)^{k-1}}{(2k)!}$ は各 Taylor 項の符号係数である.

2.1.3 PolyDice-1 Loss

PolyLoss [10] は分類タスクにおいて Cross-Entropy Loss を多項式展開し, 第 1 項のみを調整可能とすることで実用的な性能向上を達成した. PolyDice Loss [8] はこのアプローチを Dice Loss に適用したものであり, 本研究では第 1 項のみを調整する PolyDice-1 Loss を採用する.

$$\mathcal{L}_{\text{PolyDice-1}} = (1 - s) + s \left(\frac{1}{2} + \epsilon \right) \theta^2 \quad (6)$$

ここで, $\epsilon \in \mathbb{R}$ は損失関数の形状を制御するハイパーパラメータで, $\epsilon > 0$ では予測誤差に対するペナルティが強化され, $\epsilon < 0$ では緩和される. この柔軟な形状制御が可能な特性は, 本研究の適応的学習フレームワークに

おいて重要な役割を果たす. 後述する提案手法では, この ϵ を動的に調整することで, 個々の画像の難易度に応じた勾配制御を実現し, 学習戦略をサンプル単位で最適化することを可能にしている.

2.2 MC Dropout の原理と応用

Dropout は, ニューラルネットワークの過学習を防ぐ正則化手法として提案された [12]. 訓練時に各層のニューロンを確率 p でランダムに不活性化することで, モデルの汎化性能を向上させる. 通常, 推論時には Dropout は無効化され, 全ニューロンが活性化された状態で決定論的な予測が行われる.

MC Dropout [9] は, 学習時のみだけでなく, 推論時にも Dropout を有効にすることで, モデルの認識的不確実性を推定する手法である. Dropout を有効にした状態で推論を行うと, 各推論において異なるニューロンが不活性化されるため, 実質的に異なる部分ネットワークによる予測が得られる. 同一入力に対してこの確率的な推論を複数回実行して得られる予測結果の分布は, Bayesian Neural Network における予測事後分布近似とみなせ, 変分推論の一種として解釈できる.

提案法では, MC Dropout による推定される認識的不確実性を, 画像のセグメンテーション難易度を反映する指標として活用し, 損失関数の適応的制御に利用する.

3 提案法

3.1 概要

訓練データセットを $\mathcal{D} = \{(\mathbf{X}_n, \mathbf{Y}_n)\}_{n=1}^N$ とする. ここで, N は訓練画像の総数, $\mathbf{X}_n \in \mathbb{R}^{H \times W \times C}$ は n 番目の入力画像 (C はチャンネル数), $\mathbf{Y}_n = \{y_{n,i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ は対応する正解マスクである. MC Dropout による不確実性推定では, 各画像に対して T 回の確率的推論を行う. t 回目の推論 ($t \in \{1, \dots, T\}$) における予測確率マップを $\hat{\mathbf{Y}}_n^{(t)} = \{\hat{y}_{n,i,j}^{(t)}\}_{i,j}$ と表記する.

図 1 に提案手法の概要を示す. 提案法では, 学習中各画像に対して τ エポックごとに MC Dropout を用いて画像毎に複数枚推論を行い, 予測のばらつきから不確実性を定量化する. この不確実性情報は, モデルがその画像のセグメンテーションにおいてどの程度の確信を持っていないかを反映する. その後, この不確実性情報を画像単位に集約し, PolyDice Loss の形状を動的に制御することで, 難しい画像には急峻な勾配を, 簡単な画像には緩やかな勾配を与える. 更新された ϵ を次の τ エポック間の学習に適用することで, 学習の進行度に応じて最適化の重み付けを動的に変化させる適応的学習を実現する.




図1 Overview of the proposed adaptive learning framework. The process consists of two phases: uncertainty estimation and adaptive training. Every τ epochs, the model evaluates image difficulty using MC Dropout and updates the loss shape parameter ϵ . This dynamic control assigns steeper gradients to harder samples, enabling difficulty-aware optimization.

3.2 不確実性に基づく画像難易度の定量化

3.2.1 学習中の MC Dropout 推論

提案法では、学習プロセスを初期学習期間と適応的学習期間の2段階に分割する。エポック1から $E_0 - 1$ までの期間は初期学習期間とし、損失形状パラメータ ϵ を0に固定して学習を行う。適応的学習期間 ($e \geq E_0$) においては、周期 τ ごとに不確実性の再評価と ϵ の更新を行う。すなわち、更新は $e \in \{E_0, E_0 + \tau, E_0 + 2\tau, \dots\}$ を満たすエポックの学習開始前に実行される。更新の際は、その時点のモデルパラメータ $\mathbf{W}$ を固定し、訓練データの各画像 $\mathbf{X}_n \in \{\mathbf{X}_n\}_{n=1}^N$ に対して Dropout 率 $p \in (0, 1)$ で T 回の確率的推論を行う。得られる予測集合を $\{\hat{\mathbf{Y}}^{(n)}\}_{n=1}^T$ とする：

$$\hat{\mathbf{Y}}^{(n)} = f_{\mathbf{W}}(\mathbf{X}_n; \mathbf{z}^{(n)}), \quad \mathbf{z}^{(n)} \sim \text{Bernoulli}(1 - p) \quad (7)$$

ここで、 $\mathbf{z}^{(n)}$ は n 回目の推論における Dropout マスクであり、 $\hat{\mathbf{Y}}^{(n)}$ はその予測確率マップである。この確率的推論により得られる予測のばらつきから、モデルの認識的不確実性を定量化する。

3.2.2 ピクセル単位の不確実性指標の計算

MC Dropout によって得られた T 枚の予測画像に対し、ピクセル単位の不確実性指標として認識的不確実性を直接捉えることができる相互情報量 $I_{n,i,j}$ を計算する。

$$I_{n,i,j} = \underbrace{H\left(\frac{1}{T} \sum_{t=1}^T \hat{y}_{n,i,j}^{(t)}\right)}_{\text{Entropy of Mean}} - \underbrace{\frac{1}{T} \sum_{t=1}^T H\left(\hat{y}_{n,i,j}^{(t)}\right)}_{\text{Mean of Entropy}} \quad (8)$$

ここで、 $H(p)$ は2値分類におけるバイナリ・エントロピー関数であり、次式で定義される。

$$H(p) = -p \log p - (1 - p) \log(1 - p) \quad (9)$$

相互情報量はモデルの予測に付随する不確実性を評価し、その依拠する要因を分離する指標として広く用いられている。 T 回の推論結果を平均化した後の予測分布に対する不確実性であり、データとモデルの両方に由来する不確実性を示す予測エントロピーから、個々の推論における不確実性の平均であり、データ固有のノイズや曖昧さに由来する偶然的不確実性を示す期待エントロピーを減ずることで、認識的不確実性を定量化できる。値が高い領域はモデルが十分に学習できていないことを示唆する。

3.2.3 画像単位への集約

ピクセル単位の相互情報量から外れ値を除去した後の平均値を、画像全体の難易度指標として定量化する。医用画像は、関心領域である病変部が極めて小さいクラス不均衡が存在するため、画像全体で不確実性の平均を算出すると、一般に推論が容易な大量の背景画素による低い値が難易度指標全体を支配してしまい、本来捉えるべき病変部の局所的な難易度を適切に定量化できない可能性がある。

したがって、病変検出の難易度を鋭敏に反映させるため、本手法では正解画像における病変領域に限定して相互情報量の平均を算出する。画像領域全体を Ω_n 、正解マスクにおける陽性領域の画素集合を $\mathcal{P}_n = \{(i, j) \in \Omega \mid y_{i,j} = 1\}$ とする。ここで、算出される相互情報量には突発的なノイズや極端な外れ値が含まれる可能性があり、これらが難易度指標の定量化を不安定にさせる要因となる。そのため、スコアの算出に先立ち、統計的な外れ値除去を行う。具体的には、領域 $\mathcal{P}_n$ 内の相互情報量の平均を $\mu_{\mathcal{P}_n}$ 、標準偏差を $\sigma_{\mathcal{P}_n}$ とし、有効な画素集合 $\mathcal{P}'_n$ を以下のように定義する。

$$\mathcal{P}'_n = \{(i, j) \in \mathcal{P}_n \mid \mu_{\mathcal{P}_n} - 2\sigma_{\mathcal{P}_n} \leq I_{n,i,j} \leq \mu_{\mathcal{P}_n} + 2\sigma_{\mathcal{P}_n}\} \quad (10)$$

この有効集合 $\mathcal{P}'_n$ を用いて、画像全体の難易度スコア D_n は次式で算出される。

$$D_n = \frac{1}{|\mathcal{P}'_n|} \sum_{(i,j) \in \mathcal{P}'_n} I_{n,i,j} \quad (11)$$

ここで、 $|\mathcal{P}'_n|$ は外れ値除去後の陽性領域の画素数を表す。なお、陽性領域が存在しない画像については、 $D_n = 0$ とする。

次に、各サンプルの相対的な難易度を決定するため、データセット全体の難易度スコア分布に基づいて正規化

を行う。データセット全体のスコア集合 $\{D_n\}_{n=1}^N$ に対し、 q パーセンタイル値を D_q 、標準偏差を σ_D とすると、正規化されたスコア D_{norm_n} は次のように計算される。

$$D_{\text{norm}_n} = \frac{D_n - D_q}{\sigma_D + \delta} \quad (12)$$

ここで、 δ は数値的安定性のための微小定数である。 D_q による減算は、後述する制御関数への入力を合わせるための中心化をする役割を持つ。分布の平均値ではなく q パーセンタイル値を用いることで、容易なサンプルが多数を占める分布においても、外れ値の影響を受けずに難易度の基準点を柔軟に設定できる。 σ_D による除算は尺度の統一であり、制御関数の感度がデータセットごとの不確実性のスケールに依存しないように調整する役割を持つ。

3.3 適応的損失形状制御

3.3.1 制御関数の設計

得られた難易度指標 D_{norm_n} に基づき、PolyDice-1 Loss の形状パラメータ ϵ を動的に更新する。更新式には以下のシグモイドベースの制御関数を用いる。

$$\epsilon = \epsilon_{\min} + (\epsilon_{\max} - \epsilon_{\min})\sigma(k \cdot D_{\text{norm}_n}) \quad (13)$$

ここで、 $\sigma(x) = (1 + e^{-x})^{-1}$ 標準シグモイド関数、 $k > 0$ はパラメータであり、 $\epsilon_{\min}, \epsilon_{\max}$ は ϵ の変動範囲である。シグモイド関数を用いることで、難易度が低い領域から高い領域への遷移を滑らかに行いつつ、出力値を常に所定の範囲内に厳密に制約することが可能となる。パラメータ k は関数の応答感度を制御し、その値が大きいほど難易度判定の境界が急峻になり、小さいほど滑らかな遷移となる。

この制御により、難しい画像 (D_{norm_n} が大きい) に対しては、大きな ϵ を割り当て、損失関数の勾配を急峻にする。これは、同じ予測誤差に対してより大きな損失値と勾配を与えることを意味し、結果として難しい画像からの学習信号が相対的に強化される。一方、すでに十分に学習できている簡単な画像には小さな ϵ を割り当て、過学習を防ぎつつ学習リソースを難しい画像に集中させる。更新された ϵ は学習に適用され、これによりモデルは困難な画像の学習を重点的に行うことが可能となる。

3.3.2 学習アルゴリズム

学習プロセスは難易度評価と損失パラメータ更新を行う適応的制御と、実際にモデルパラメータを更新する学習段階の2つで構成される。

学習開始時、モデルパラメータ $\mathbf{W}$ を初期化し、全ての画像に対する損失形状パラメータ ϵ を 0 に初期化する。

$E_0 > 0$ の場合、エポック 1 から $E_0 - 1$ までの期間は初期学習期間とし、 $\epsilon = 0$ を固定して標準的な PolyDice-1 Loss で学習を行う。この期間により、モデルは不確実性推定に必要な基礎的な特徴表現を獲得する。 $E_0 = 0$ の場合は、最初のエポックから適応的制御を開始する。

適応的学習期間 ($e \geq E_0$) では、 τ エポックごとに適応的制御が実行される。ここでは、3.2 節で述べた手順に従い、MC Dropout 推論による不確実性指標推定、画像単位への集約、正規化を経て、各画像の ϵ が更新される。適応的制御の段階ではモデルパラメータ $\mathbf{W}$ は固定されており、損失関数の形状パラメータ ϵ の更新のみが行われることに注意されたい。

続く学習段階 (Epoch e) では、更新された ϵ を用いてミニバッチ学習を行う。具体的には、ランダムにサンプリングされたミニバッチを構成する画像のインデックス集合を $B \subset \{1, \dots, N\}$ とする。このとき、最適化の対象となる目的関数 $\mathcal{L}$ は、バッチ内の各画像 $n \in B$ に個別に割り当てられた形状パラメータ ϵ_n を用いた PolyDice-1 Loss の平均として次式で定義される。

$$\mathcal{L} = \frac{1}{|B|} \sum_{n \in B} \mathcal{L}_{\text{PolyDice-1}}(\hat{\mathbf{Y}}_n, \mathbf{Y}_n; \epsilon_n) \quad (14)$$

ここで、 $\mathcal{L}_{\text{PolyDice-1}}(\cdot; \epsilon_n)$ はパラメータ ϵ_n を適用した単一画像の損失関数を表す。このように、バッチ内の各画像に対して異なる ϵ_n を適用することで、難易度が高いと判定された画像には急峻な勾配を、低い画像には緩やかな勾配を同時に与えることが可能となる。最終的に、この損失関数 $\mathcal{L}$ に基づく勾配降下法により、モデルパラメータ $\mathbf{W}$ が最適化される。このサイクルを繰り返すことで、モデルの学習に応じて困難な画像の学習を重点的に行うことが可能となる。

4 実験

4.1 実験設定

4.1.1 データセット

CVC-ClinicDB データセット [13] データセットおよび Kvasir-SEG データセット [14] を用いて実験を行った。CVC-ClinicDB データセットは 612 枚の大腸内視鏡画像 (384×288 pixel)、Kvasir-SEG データセットは 1000 枚の大腸内視鏡画像で、いずれも大腸内視鏡画像とそれに対応するポリープの正解マスクから構成される。データは 5 分割交差検証で分割され、CVC-ClinicDB データセットに関しては同一のビデオシーケンスが異なる fold に跨がらないよう、GroupKFold を用いた分割を行った。

4.1.2 実装の詳細

セグメンテーションモデルには U-Net [15] を採用した。学習には Adam optimizer [16] を使用し、バッチサイズ 32, 学習率 10^{-3} に設定した。前処理として全画像を $W = 224$ pixel, $H = 224$ pixel にリサイズし、訓練時には 50% の確率で上下左右反転および明度・コントラストの変更を適用した。最大エポック数 E は 200 に設定した。

MC Dropout による不確実評価は、 $\tau = 10$ エポックごとに実施した。Dropout 層はエンコーダの最終ブロックとデコーダの最終ブロックに配置し、各評価時には、先行研究 [9] を基に $p = 0.5$ で $T = 10$ 回の確率的推論を行った。またデータセット内の難易度指標の正規化時のパーセンタイルは難易度分布の偏りを考慮して $q = 25$ に設定し、予備実験の結果を基に適応的学習の開始エポックは $E_0 = 10$ とし、 $\epsilon_{\min} = 0$, $\epsilon_{\max} = 0.5$, $k = 2$ とした。

4.1.3 比較条件および比較指標

適応的学習の有効性を評価するため、以下の手法と提案法を比較する：

- Dice Loss [4]：医用画像セグメンテーションにおける標準的な損失関数であり、ベースラインとして採用した。
- Focal Loss [17]：易しいサンプルの損失を down-weight することでクラス不均衡に対処する手法で、易しいサンプルの損失を down-weight する割合は $\gamma = 2$ とした。
- PolyDice-1 Loss ($\epsilon = 0$)：PolyDice-1 Loss の標準形式であり、理論上は通常の Dice Loss を近似したものである。提案法および後述する Optimal 設定との比較において、パラメータ ϵ を操作すること自体の純粋な効果を検証するための基準として採用した。
- PolyDice-1 Loss (optimal)：固定 ϵ による性能の理論的上界を評価するため、テストデータに対する Dice 係数を最大化する ϵ 値を事後的に探索し、これを理想設定として比較に含めた。具体的には、 $\epsilon \in \{-0.3, -0.2, \dots, 0.5\}$ の範囲で網羅的に評価し、最高精度を達成する値 ϵ をデータセットごとに決定した。この設定は実運用では実現不可能であるが、「最適固定値が事前に既知である」という理想的な条件下での性能を表す。

これらの比較により、(1) 提案法が標準的な損失関数より優れているか、(2) 適応的 ϵ 制御が固定 $\epsilon = 0$ より

表 1 Performance Comparison with Existing Loss Functions on CVC-ClinicDB Dataset

Method	Dice	IoU	Precision	Recall
Dice Loss	0.5408	0.4347	0.6359	0.5819
Focal Loss ($\gamma = 2$)	0.5007	0.4133	0.7078	0.4707
PolyDice-1 ($\epsilon = 0$)	0.5825	0.4808	0.6817	0.6167
PolyDice-1 (Opt. $\epsilon = 0.4$)	0.6145	0.5145	0.7090	0.6372
Adaptive PolyDice-1	0.6924	0.5262	0.7827	0.7113

表 2 Performance Comparison with Existing Loss Functions on Kvasir-SEG Dataset

Method	Dice	IoU	Precision	Recall
Dice Loss	0.7895	0.7021	0.8281	0.8154
Focal Loss ($\gamma = 2$)	0.7192	0.6082	0.8634	0.6769
PolyDice-1 ($\epsilon = 0$)	0.8095	0.7198	0.8461	0.8268
PolyDice-1 (Opt. $\epsilon = 0.0$)	0.8095	0.7198	0.8461	0.8268
Adaptive PolyDice-1	0.8272	0.7440	0.8707	0.8397

有効か、(3) 提案法が Optimal 設定に匹敵あるいは上回る性能を達成できるか、を検証する。

またセグメンテーションの性能の評価には、領域の重なりを測る Dice 係数（主指標）および IoU および検出精度を測る Precision および Recall を用いた。予測マスクには予測マップ Y_n を閾値 0.5 で二値化したものを用い、各指標はテストデータ全体での平均値を報告する。

4.2 結果と議論

4.2.1 比較手法との性能比較：

全データセットでの比較表

4.2.2 難易度別の評価

難しい画像に対してどれくらいうまくいったか定量的に評価

4.2.3 定性的評価

成功・失敗例の特徴分析、今後の改善方向を示唆

5 まとめ

卒業論文発表予稿の様式を示しました。

参考文献

- [1] G.-P. Ji *et al.*, “Video polyp segmentation: A deep learning perspective,” *Machine Intelligence Research*, vol. 19, no. 6, pp. 531–549, 2022.
- [2] F. Maleki *et al.*, “Machine learning applications for head and neck imaging,” *Neuroimaging Clinics*, vol. 30, no. 4, pp. 517–529, 2020.
- [3] J. Long *et al.*, “Fully convolutional networks for semantic segmentation,” in *Proceedings of the*

- IEEE Conference on Computer Vision and Pattern Recognition*, 2015, pp. 3431–3440.
- [4] F. Milletari *et al.*, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” in *2016 Fourth International Conference on 3D Vision (3DV)*. Ieee, 2016, pp. 565–571.
 - [5] W. Zhu *et al.*, “AnatomyNet: deep learning for fast and fully automated whole-volume segmentation of head and neck anatomy,” *Medical Physics*, vol. 46, no. 2, pp. 576–589, 2019.
 - [6] G. Wang *et al.*, “A noise-robust framework for automatic segmentation of COVID-19 pneumonia lesions from ct images,” *IEEE Transactions on Medical Imaging*, vol. 39, no. 8, pp. 2653–2663, 2020.
 - [7] S. Kato and K. Hotta, “Adaptive t-vMF dice loss: An effective expansion of dice loss for medical image segmentation,” *Computers in Biology and Medicine*, vol. 168, p. 107695, 2024.
 - [8] H. Aizawa, “Polynomial dice loss for medical image segmentation(submitted).”
 - [9] Y. Gal and Z. Ghahramani, “Dropout as a Bayesian approximation: Representing model uncertainty in deep learning,” in *Proceedings of The 33rd International Conference on Machine Learning*, vol. 48, 20–22 Jun 2016, pp. 1050–1059.
 - [10] Z. Leng *et al.*, “Polyloss: A polynomial expansion perspective of classification loss functions,” in *International Conference on Learning Representations*, 2022.
 - [11] L. Smith and Y. Gal, “Understanding measures of uncertainty for adversarial example detection,” *arXiv preprint arXiv:1803.08533*, 2018.
 - [12] N. Srivastava *et al.*, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.
 - [13] J. Bernal *et al.*, “WM-DOVA maps for accurate polyp highlighting in colonoscopy: Validation vs. saliency maps from physicians,” *Computerized Medical Imaging and Graphics*, vol. 43, pp. 99–111, 2015.
 - [14] D. Jha *et al.*, “Kvasir-seg: A segmented polyp dataset,” in *Proceedings of the 26th International Conference on Multimedia Modeling (MMM 2020), Part II*, ser. Lecture Notes in Computer Science, vol. 11962. Springer, 2020, pp. 451–462.
 - [15] O. Ronneberger *et al.*, “U-net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer, 2015, pp. 234–241.
 - [16] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
 - [17] T.-Y. Lin *et al.*, “Focal loss for dense object detection,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 2980–2988.
 - [18] J. T. Kajiya, “The rendering equation,” in *Proceedings of the 13th Annual Conference on Computer Graphics and Interactive Techniques*, 1986, pp. 143–150.
 - [19] H. W. Jensen, *Realistic image synthesis using photon mapping*. Ak Peters Natick, 2001, vol. 364.