

修士論文要旨

Summary of the Master's Thesis

学 生 番 号 Student ID number	M243422	プ ロ グ ラ ム Program	情報科学プログラム
氏 名 Name	廣池 友哉	主 指 導 教 員 Supervisor	古居 彬
論 文 題 目 Thesis Title	Adaptive PolyDice Loss with Uncertainty-Based Difficulty Estimation for Medical Image Segmentation		

1 はじめに

医用画像セグメンテーションは、診断支援や治療計画において不可欠な技術であり、正常組織または異常組織の領域を抽出することが求められる。特に大腸ポリープ [1] の検出など、臨床応用が進んでいる。

しかしながら、医用画像セグメンテーションには固有の課題が存在する。特に重要な問題として、クラス不均衡が挙げられる。医用画像では背景領域が大部分を占め、対象となる病変は相対的に小さい領域しか占めないことが多い。この状況下では、従来の分類タスクで広く使われている Cross-Entropy Loss [2] は背景領域の学習に偏り、臨床的に重要な小病変や曖昧な境界部分の正確なセグメンテーションが困難となる。

この課題に対処するため、クラス不均衡に対して頑健な Dice Loss [3] やその多くの拡張手法が提案され、CT 画像や MRI 画像において高い性能が報告されている。しかし、これらの損失関数は全画像に対して固定的な形状を持つという制約がある。医用画像は、撮影条件や個体差など大きな多様性を有しており、画像ごとにセグメンテーションの難易度が大きく異なる。固定的な損失関数を用いると、容易な画像と困難な画像に対して同一の学習信号を与えるため、困難な画像に対する学習が不十分となる可能性がある。したがって、画像ごとの難易度に応じて損失関数を適応的に調整するアプローチが有望である。

このような適応的学習の実現には、2つの要素が求められる。1つは、難易度の高い画像に対して学習信号を強化できるよう、損失関数の形状を柔軟に制御する手法である。もう1つは、各画像がモデルにとってどの程度困難であるかを学習中に評価するための難易度指標である。

本研究では、これら2つの要素を統合した適応的学習フレームワークを提案する。損失関数の形状制御には、Dice Loss を多項式展開して得られる PolyDice Loss [4] を用いる。PolyDice Loss は画像毎に最適なパラメータを用いて損失関数の形状を連続的に制御できるため、適応的学習に適している。難易度の定量化には、Monte Carlo Dropout [5] (以下、MC Dropout) による不確実性推定を用いる。MC Dropout は、推論時に Dropout を有効にすることで、モデルの認識的不確実性を効率的に推定できる。この不確実性は、モデルがその画像のセグメンテーションにおいてどの程度の確信を持てないかを反映しており、セグメンテーション難易度の指標として利用可能である。提案手法では、推定された不確実性指標に基づき PolyDice Loss の形状パラメータを動的に制御し、困難な画像には急峻な勾配を、容易な画像には緩やかな勾配を与えることで、効率的かつ頑健な学習の実現を目指す。

2 予備知識

2.1 PolyDice Loss

医用画像セグメンテーションで広く使用される Dice Loss は、クラス不均衡に頑健であるが、全画像に対して固定的な形状を持つという制約がある。本研究では、Dice Loss を多項式展開により拡張した PolyDice Loss [4]、特にその実用的な形式である PolyDice-1 Loss を採用する。

画像サイズを $H \times W$ とし、モデルの予測確率マップを $\hat{\mathbf{Y}} = \{\hat{y}_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ 、正解マスクを $\mathbf{Y} = \{y_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ とすると、Dice Loss は次式で定義される。

$$\mathcal{L}_{\text{Dice}}(\hat{\mathbf{Y}}, \mathbf{Y}) = 1 - \frac{2 \sum_{j=1}^W \sum_{i=1}^H \hat{y}_{i,j} y_{i,j}}{\sum_{j=1}^W \sum_{i=1}^H (\hat{y}_{i,j}^2 + y_{i,j}^2)} \quad (1)$$

$\hat{\mathbf{Y}}$ と $\mathbf{Y}$ をそれぞれ長さ HW のベクトル $\hat{\mathbf{y}}, \mathbf{y}$ として平坦化すると, Dice Loss はスケール成分 $s = \frac{2\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\|^2 + \|\mathbf{y}\|^2}$ とベクトル間の角度 $\theta = \arccos \frac{\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\| \|\mathbf{y}\|}$ を用いて $L_{\text{Dice}} = 1 - s \cos \theta$ と分解できる. この角度成分 $\cos \theta$ を $\theta = 0$ まわりで Taylor 展開し, 第 1 項のみを調整可能としたものが PolyDice-1 Loss である:

$$\mathcal{L}_{\text{PolyDice-1}} = (1 - s) + s \left(\frac{1}{2} + \epsilon \right) \theta^2 \quad (2)$$

ここで, $\epsilon \in \mathbb{R}$ は損失関数の形状を制御するハイパーパラメータである. $\epsilon > 0$ では予測誤差に対するペナルティが強化され, $\epsilon < 0$ では緩和される. 本研究では, この ϵ を画像難易度に応じて動的に調整する.

2.2 MC Dropout による不確実推定

Dropout [5] は, ニューラルネットワークの過学習を防ぐ正則化手法であり, 訓練時に各層のニューロンを確率 p でランダムに不活性化することで, モデルの汎化性能を向上させる. MC Dropout [5] は, 推論時にも Dropout を有効にすることで, モデルの認識的不確実性を推定する手法である. 同一入力に対して T 回の確率的推論を行い, 予測分布のばらつきから不確実性を定量化する. 本研究では, この認識的不確実性を画像のセグメンテーション難易度を反映する指標として活用する.

3 提案法

3.1 概要

訓練データセットを $\mathcal{D} = \{(\mathbf{X}_n, \mathbf{Y}_n)\}_{n=1}^N$ とする. ここで, N は訓練画像の総数, $\mathbf{X}_n \in \mathbb{R}^{H \times W \times C}$ は n 番目の入力画像 (C はチャンネル数), $\mathbf{Y}_n = \{y_{n,i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ は対応する正解マスクである.

図 1 に提案手法の概要を示す. 提案法は, (1) MC Dropout による不確実性推定に基づく 画像難易度の定量化, (2) 難易度に応じた PolyDice-1 Loss の形状パラメータ ϵ の動的制御, の 2 つの要素から構成される.

学習過程は, 通常の学習段階と適応的制御段階の 2 つのフェーズを交互に実行する. 適応的制御段階では, τ エポックごとにモデルパラメータを固定し, 各画像に対して MC Dropout による画像毎に複数回の確率的推論を行う. 得られた予測のばらつきから認識論的不確実性を定量化し, これを画像単位の難易度スコアに集約する. この難易度スコアに基づき, 難しい画像には大きな ϵ (急峻な勾配) を, 簡単な画像には小さな ϵ (緩やかな勾配) を与える. 続く学習段階では, 更新された ϵ を用いてモデルパラメータを定期化する. このサイクルを繰り返すことで, 学習の進行に応じて最適化の重み付けを動的に変化させる適応的学習を実現する.




図 1 Overview of the proposed adaptive learning framework

3.2 不確実性に基づく画像難易度の定量化

3.2.1 学習中の MC Dropout 推論

適応的学習は, 初期学習期間 (エポック 1 から $E_0 - 1$) の後, 周期 τ 毎に実行される. すなわち, 更新は $e \in \{E_0, E_0 + \tau, E_0 + 2\tau, \dots\}$ を満たすエポックの学習開始前に実行される. 初期学習期間では, $\epsilon = 0$ に固定した標準的な PolyDice-1 Loss で学習を行い, モデルに不確実性推定の基盤となる特徴表現を獲得させる. 適応的制御段階では, モデルパラメータ $\mathbf{W}$ を固定し, 訓練データの各画像 $\mathbf{X}_n$ に対して Dropout 率 $p \in (0, 1)$ で T 回の確率的推論を行う. 得られる予測集合を $\{\hat{\mathbf{Y}}_n^{(t)}\}_{t=1}^T$ とする:

$$\hat{\mathbf{Y}}_n^{(t)} = f_{\mathbf{W}}(\mathbf{X}_n; \mathbf{z}^{(t)}), \quad \mathbf{z}^{(t)} \sim \text{Bernoulli}(1 - p) \quad (3)$$

ここで, $\mathbf{z}_n^{(t)}$ は t 回目の推論における Dropout マスクであり, $\hat{\mathbf{Y}}_n^{(t)}$ はその予測確率マップである. この確率的推論により得られる予測のばらつきから, モデルの認識的不確実性を定量化する.

3.2.2 ピクセル単位の不確実性指標の計算

T 回の確率的推論から得られた予測画像に対し, ピクセル単位の認識的不確実性として相互情報量 $I_{n,i,j}$ を計算する.

$$I_{n,i,j} = \underbrace{H \left(\frac{1}{T} \sum_{t=1}^T \hat{y}_{n,i,j}^{(t)} \right)}_{\text{Entropy of Mean}} - \underbrace{\frac{1}{T} \sum_{t=1}^T H \left(\hat{y}_{n,i,j}^{(t)} \right)}_{\text{Mean of Entropy}} \quad (4)$$

ここで, $H(p)$ は 2 値分類におけるバイナリエントロピー関数であり, 次式で定義される.

$$H(p) = -p \log p - (1 - p) \log (1 - p) \quad (5)$$

認識的不確実性は, 予測エントロピーから期待エントロピーを減ずることで定量化できる. 予測エントロピーは T 回の推論平均に対する不確実性であり, データとモデルの両方に由来する. 一方, 期待エントロピーは個々の推論における不確実性の平均であり, データ固有のノ

イズや曖昧さに由来する。相互情報量の値が高い領域はモデルが十分に学習できていないことを示唆する。

3.2.3 画像単位への集約

ピクセル単位の相互情報量から外れ値を除去した後の平均値を、画像全体の難易度指標として集約して定量化する。集約する際、不均衡な医用画像の病変部の不確実性を定量化するため、本手法では計算対象を正解マスクにおける陽性領域 $\mathcal{P}_n = \{(i, j) \in \Omega_n \mid y_{i,j} = 1\}$ に限定する。ここで、 Ω_n は画像領域全体を表す。具体的な算出には、突発的なノイズの影響を排除するために統計的な外れ値除去を適用する。 $\mathcal{P}_n$ 内の平均 $\mu_{\mathcal{P}_n}$ と標準偏差 $\sigma_{\mathcal{P}_n}$ を用いて有効画素集合 $\mathcal{P}'_n$ を定義する。

$$\mathcal{P}'_n = \{(i, j) \in \mathcal{P}_n \mid \mu_{\mathcal{P}_n} - 2\sigma_{\mathcal{P}_n} \leq I_{n,i,j} \leq \mu_{\mathcal{P}_n} + 2\sigma_{\mathcal{P}_n}\} \quad (6)$$

この有効集合 $\mathcal{P}'_n$ を用いて、画像全体の難易度スコア D_n は次式で算出される。

$$D_n = \frac{1}{|\mathcal{P}'_n|} \sum_{(i,j) \in \mathcal{P}'_n} I_{n,i,j} \quad (7)$$

なお、 $\mathcal{P}_n = \emptyset$ の場合は $D_n = 0$ とする。

次に、各サンプルの相対的な難易度を決定するため、データセット全体の難易度スコア分布に基づいて正規化を行う。データセット全体のスコア集合 $\{D_n\}_{n=1}^N$ に対し、 q パーセンタイル値を D_q 、標準偏差を σ_D とすると、正規化されたスコアは次のように計算される。

$$D_n^{\text{norm}} = \frac{D_n - D_q}{\sigma_D + \delta} \quad (8)$$

ここで、 $\delta > 0$ は数値的安定性のための微小定数である。 D_q による中心化は、容易なサンプルが多数を占める医用画像データセットにおいて、外れ値に頑健な難易度の基準点の設定を可能にする。

3.3 適応的損失形状制御

3.3.1 制御関数の設計

得られた難易度指標 D_n^{norm} に基づき、PolyDice-1 Loss の形状パラメータ ϵ_n を動的に更新する。更新式には以下のシグモイドベースの制御関数を用いる。

$$\epsilon_n = \epsilon_{\min} + (\epsilon_{\max} - \epsilon_{\min})\sigma(k \cdot D_n^{\text{norm}}) \quad (9)$$

ここで、 $\sigma(x) = (1 + e^{-x})^{-1}$ は標準シグモイド関数、 $k > 0$ は応答感度を制御するパラメータであり、 $\epsilon_{\min}, \epsilon_{\max}$ は ϵ_n の変動範囲である。

シグモイド関数の採用により、出力値を $[\epsilon_{\min}, \epsilon_{\max}]$ の範囲内に厳密に制約しつつ、難易度の低い領域から高い領域への滑らかな遷移を実現する。この制御により、難しい画像 (D_n^{norm} が大きい) には大きな ϵ_n が割り当てられ、同じ予測誤差に対してより大きな勾配が与えら

れる。一方、容易な画像には小さな ϵ_n が割り当てられ、過学習を抑制しつつ学習リソースを難しい画像に集中させる。

3.3.2 学習アルゴリズム

学習は以下の手順で実行する。まず、モデルパラメータ $\mathbf{W}$ を初期化し、全ての画像に対する損失形状パラメータ ϵ を 0 に初期化する。エポック 1 から $E_0 - 1$ までの初期学習期間では、 $\epsilon = 0$ を固定した標準的な PolyDice-1 Loss による学習を行う。この期間で、モデルは基礎的な特徴表現を獲得する。

エポック E_0 以降の適応的学習期間では、 τ エポックごとに適応的制御を実行する。現時点でのモデルパラメータ $\mathbf{W}$ を固定し、3.2 節の手順に従って、各画像の難易度スコアを算出した後、式 (7) により各画像の ϵ_n を更新する。

各エポックの学習段階では、ミニバッチ $\mathcal{B} \subset \{1, \dots, N\}$ に対して以下の損失関数を最適化する：

$$\mathcal{L} = \frac{1}{|\mathcal{B}|} \sum_{n \in \mathcal{B}} \mathcal{L}_{\text{PolyDice-1}}(\hat{\mathbf{Y}}_n, \mathbf{Y}_n; \epsilon_n) \quad (10)$$

ここで、 $\mathcal{L}_{\text{PolyDice-1}}(\cdot; \epsilon_n)$ は画像 n に割り当てられた形状 ϵ_n を用いた PolyDice-1 Loss である。このように、同一バッチ内であっても各画像に異なる ϵ_n を適用することで、難易度が高いと判定された画像には急峻な勾配を、低い画像には緩やかな勾配を同時に与えることが可能となる。適応的制御と学習のサイクルを最終エポック E まで繰り返すことで、学習の進行に伴いモデルが困難と認識する画像が変化しても、それに追従した適応的な学習が可能となる。

4 実験

4.1 実験設定

4.1.1 データセット

CVC-ClinicDB データセット [6] データセットおよび Kvasir-SEG データセット [7] を用いて実験を行った。CVC-ClinicDB データセットは 612 枚の大腸内視鏡画像 (384×288 pixel)、Kvasir-SEG データセットは 1000 枚の大腸内視鏡画像で、いずれも大腸内視鏡画像とそれに対応するポリープの正解マスクから構成される。データは 5 分割交差検証で分割され、CVC-ClinicDB データセットに関しては同一のビデオシーケンスが異なる fold に跨がらないよう、GroupKFold を用いた分割を行った。

4.1.2 実装の詳細

セグメンテーションモデルには U-Net [8] を採用した。学習には Adam optimizer [9] を使用し、バッチサ

イズ 32, 学習率 10^{-3} , 最大エポック数 $E = 200$ に設定した. 前処理として全画像を $W = 224$ pixel, $H = 224$ pixel にリサイズし, 訓練時には 50% の確率で上下左右反転および明度・コントラストの変更を適用した.

MC Dropout による不確実評価は, $\tau = 10$ エポックごとに実施した. Dropout 層はエンコーダの最終ブロックとデコーダの最終ブロックに配置し, 各評価時には, 先行研究 [5] を基に $p = 0.5$ で $T = 10$ 回の確率的推論を行った. またデータセット内の難易度指標の正規化時のパーセンタイルは難易度分布の偏りを考慮して $q = 25$ に設定し, 予備実験の結果を基に適応的学習の開始エポックは $E_0 = 10$ とし, $\epsilon_{\min} = 0$, $\epsilon_{\max} = 0.5$, $k = 2$ とした.

4.1.3 比較条件および比較指標

適応的学習の有効性を評価するため, 以下の手法と提案法を比較する:

- Dice Loss [3]: 医用画像セグメンテーションにおける標準的な損失関数.
- Focal Loss [10]: 容易なサンプルの損失を低減する手法 ($\gamma = 2$).
- PolyDice-1 Loss ($\epsilon = 0$): 提案法のベースラインとなる標準形式.
- PolyDice-1 Loss (optimal): テストデータに対する Dice 係数を最大化する ϵ を事後的に探索した理想設定. この設定は実運用では実現不可能であるが, 「最適な固定値が事前に既知である」という理想的な条件下での性能を表す.

これらの比較により, (1) 提案法が標準的な損失関数より優れているか, (2) 適応的 ϵ 制御が固定 $\epsilon = 0$ より有効か, (3) 提案法が Optimal 設定に匹敵あるいは上回る性能を達成できるか, を検証する.

性能の評価には, 領域の重なりを測る Dice 係数 (主指標) および IoU を用いた. 最終的な性能評価時の予測マスクには予測マップ $\hat{Y}_n$ を閾値 0.5 で二値化したものをを用い, 各指標はテストデータ全体での平均値を報告する.

4.2 結果と議論

4.2.1 比較手法との性能比較:

表 1 に, 各データセットにおける比較手法との性能比較を示す. 両方のデータセットにおいて, 提案法は全ての比較手法を上回る性能を達成した. Focal Loss は両データセットにおいて Dice Loss を下回る結果となった. Focal Loss は容易なサンプルの損失を低減する設計であるが, セグメンテーションでは画像内のピクセル単

表 1 Performance Comparison on CVC-ClinicDB and Kvasir-SEG Datasets. Bold indicates the best result.

Method	CVC-ClinicDB		Kvasir-SEG	
	Dice	IoU	Dice	IoU
Dice Loss	0.5408	0.4347	0.7895	0.7021
Focal Loss	0.5007	0.4133	0.7192	0.6082
PolyDice-1 ($\epsilon = 0$)	0.5825	0.4808	0.8095	0.7198
PolyDice-1 (Opt.)	0.6145	0.5145	0.8095	0.7198
Adaptive (Ours)	0.6924	0.5262	0.8272	0.7440

位で不均衡が生じるため, 画像全体の難易度を考慮しないこの戦略は有効に機能しなかったと考えられる.

テストデータに対して最適な固定 ϵ を事後探索した PolyDice-1 Loss (optimal) をも上回った. 固定 ϵ では全画像に同一の勾配特性が適用されるため, 容易な画像への過学習と困難な画像の学習不足が同時に生じうる. また, 学習進行に伴う各画像の相対的難易度の変化にも追従できない. 提案法は τ エポックごとに難易度を再評価することで, これらの問題を回避している.

4.2.2 難易度別の評価

提案手法の設計意図である「困難な症例に対しては急峻な勾配を与え, 容易な症例に対しては緩やかな勾配を与える」という適応的学習戦略の有効性を検証するため, 症例の難易度に基づいた性能比較を行った. 具体的には, Dice Loss におけるテストデータの Dice 係数に基づき, 全症例を 3 つの難易度層に分類した. 下位 33 パーセンタイル未満の症例を「困難 (Hard)」, 33 パーセンタイル以上 66 パーセンタイル未満を「中程度 (Medium)」, 66 パーセンタイル以上を「容易 (Easy)」と定義した.

図 2 に, 両データセットの各難易度層における性能比較を示す. 困難な症例群において Dice 係数が CVC-ClinicDB で 0.36, Kvasir-SEG で 0.13 上昇した. これは, 予測が不確実で困難な症例に対して大きな ϵ を割り当て, 損失関数の勾配を急峻にしたことで, モデルがこれらの画像の特徴を重点的に学習できたことを示唆している. 一方で, 容易および中程度の症例群においては, 精度変化が小さく一部でわずかな低下も見られた. この結果は, 十分に学習された症例からの勾配を抑制するという設計意図を反映したものであり, モデルが特定の容易なパターンに対して過学習することを防いだ結果と解釈できる.

4.2.3 定性的評価

図 3 に, CVC-ClinicDB データセットにおける各難易度層の画像の比較手法と提案法のセグメンテーション




図2 Performance comparison on CVC-ClinicDB and Kvasir-SEG datasets




図3 Qualitative comparison of segmentation results on CVC-ClinicDB dataset. Rows show easy, medium, and hard cases.

結果を示す。境界が明瞭な容易な画像と中程度の画像においては、既存手法と提案法の両方が高精度なセグメンテーションを実現している。一方、ポリープと粘膜壁のコントラストが低く、境界が不明瞭である困難な症例において、ベースラインである Dice Loss や Focal Loss ではポリープ領域を捉えきれず、著しい過少検出が発生し、PolyDice-1 Loss (optimal) でも検出が不完全である。

これに対し、提案法は高精度なセグメンテーションを実現している。これは、提案法が MC Dropout によりこのような症例を困難な画像と判定し、損失関数の形状パラメータ ϵ を大きく設定したことで、学習時に当該症例に対する勾配が強化され、モデルの特徴抽出能力が向上した結果であると考えられる。

5 まとめ

本稿では、医用画像セグメンテーションにおける適応的学習手法を提案した。提案法では、MC Dropout を用いてモデルの認識的不確実性を定量化し、これを画像の

セグメンテーション難易度の指標として活用する。得られた難易度指標に基づき、PolyDice-1 Loss の形状パラメータを動的に制御することで、難しい画像には急峻な勾配を、簡単な画像には緩やかな勾配を与える適応的学習を実現した。

CVC-ClinicDB および Kvasir-SEG データセットを用いた評価実験において、提案法は Dice Loss や Focal Loss などの既存手法に加え、理想的な固定パラメータ設定をも上回る性能を達成した。特に、従来手法では抽出が困難であった症例群に対して、CVC-ClinicDB において Dice 係数が 0.36 向上するなど、提案する適応的学習戦略が困難な病変の検出に有効であることが示された。今後はハイパーパラメータの自動最適化や、CT や MRI などの 3 次元医用画像への拡張に取り組む予定である。

参考文献

- [1] G.-P. Ji *et al.*, “Video polyp segmentation: A deep learning perspective,” *Machine Intelligence*

- Research*, vol. 19, no. 6, pp. 531–549, 2022.
- [2] J. Long *et al.*, “Fully convolutional networks for semantic segmentation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015, pp. 3431–3440.
 - [3] F. Milletari *et al.*, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” in *2016 Fourth International Conference on 3D Vision (3DV)*. Ieee, 2016, pp. 565–571.
 - [4] H. Aizawa, “Polynomial dice loss for medical image segmentation (submitted).”
 - [5] Y. Gal and Z. Ghahramani, “Dropout as a Bayesian approximation: Representing model uncertainty in deep learning,” in *Proceedings of The 33rd International Conference on Machine Learning*, vol. 48, 20–22 Jun 2016, pp. 1050–1059.
 - [6] J. Bernal *et al.*, “WM-DOVA maps for accurate polyp highlighting in colonoscopy: Validation vs. saliency maps from physicians,” *Computerized Medical Imaging and Graphics*, vol. 43, pp. 99–111, 2015.
 - [7] D. Jha *et al.*, “Kvasir-SEG: A segmented polyp dataset,” in *Proceedings of the 26th International Conference on Multimedia Modeling (MMM 2020), Part II*, ser. Lecture Notes in Computer Science, vol. 11962. Springer, 2020, pp. 451–462.
 - [8] O. Ronneberger *et al.*, “U-net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer, 2015, pp. 234–241.
 - [9] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
 - [10] T.-Y. Lin *et al.*, “Focal loss for dense object detection,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 2980–2988.